

MARSA 项目规划书（v2 · 全新）

一个会自己迭代算法的 Coding Agent —— 以 Ramsey 数为应用场景

Autonomous Algorithm-Iterating Coding Agent

人工智能选修课大作业 · 学期级项目规划 姓名：曹成博 学号：2452035

本规划书取代 v1。v1 的重心是"记忆增强的搜索算法"，实测后我们据此修正了方向；修正依据见 §2，v1 由 git 历史保留。

〇、给老师的三句话

- 我们要做的是 **一个 Agent**，不是一套搜索算法：用户下达任务，它自己读代码、改算法、跑测试、做评测、保留或回退，无人值守地一轮轮迭代，并留下可审查的决策日志。
- 应用场景是 Ramsey 数 $R(5,5)$ 的反例构造——一个真实的未解决问题。选它不是因为 数学好看，而是因为它的成功可以被**精确、独立地验证**：这既是硬环境的保证，也是防止 Agent"编造成功"（reward hacking）的关键。
- 地基已经打好了**：可精确验证的实验环境（独立验证器 + 评测场 + 34 项回归测试）已建成并验收；接下来是把这个环境交给一个真正的 Coding Agent 去用。

一、对任务的理解

作业要求是"开发一个智能体，并应用它研究基础数学/应用数学的某个未解决问题"。主体是智能体，数学问题是它的应用场景。

因此本项目的定位是：

层次	内容
交付物（主体）	一个能自主迭代算法的 Coding Agent：有显式运行规则、能无人值守地循环改进自己使用的算法
应用场景（客体）	Ramsey 数 $R(5,5)$ 的反例构造
评价方式	Agent 的自主性、决策质量、以及它迭代出的算法是否真的更好

二、设计依据：对齐课程参考材料

我们的架构不是自己拍脑袋设计的，而是逐条对齐《AI Agents in Depth》：

课程材料	我们如何落地
§5 Coding Agent 与通用 Agent：Coding 是	本项目的 Agent 就是 Coding Agent：它的核心动

Agent 的基础能力	作是"读懂现有代码 → 定向修改算法 → 验证"
§5.2.6 代码创造代码：Agent 自举 —— 明确区分"DNA 复制（随机变异 + 盲目试错）"与"Agent 自举（理解代码 + 定向设计）"	我们走后者：Agent 必须读懂现有算法代码再定向改进，且继承经过验证的框架，只改工具与策略层
§5.2.6 两层架构（OpenClaw Doctor 案例）：确定性检查打底 + LLM 兜底长尾	我们的决策层就是两层的：高频、有明确规则的动作（停滞判定、预算分配、回归门禁、回退）用确定性规则；疑难问题（归因失败原因、提出新算法思路）才交给 LLM
§5.1.3 Coding Agent 整体流程：探索调研 → 设计文档 → 实现与测试 → 代码审查 → 文档同步	Agent 每一轮迭代都走这条流程，且"测试通过"才是完成标准，不是"代码写完"
§5.1.4 Harness 四原则：① 约束优先于指导 ② 验证要自动化 ③ 反馈越快越结构化越好 ④ 回退要可靠	① 新算法要上台，必须先过 34 项回归测试——这是"做不了"而不是"建议别做"；② 评测全自动；③ 每轮输出结构化结果记录；④ 每轮可回退（版本化 + 快照）
§5.1.5 故障分类学（四层故障）：API 层 / 工具层 / 上下文层 / 控制流层	直接实现为 Agent 的错误处理模块，尤其针对书里点名的最危险故障："工具反复返回同一错误，而不加改变地反复重试"
§2.5 动态提示词与 Agent Skills —— 三层渐进式披露（元数据目录常驻 / SKILL.md 按需加载 / 子文档深入）	算法的可复用知识写成 Skill: name + description（写成路由条件："何时用我 / 何时别用我"）常驻，完整正文按需读
§3.1.4 进阶知识表示形态：可执行代码	Agent 的知识库存的是可执行的算法变体 + 实测性能，而不是"过去找到的解"

§5.1.4 里有一句我们要专门遵守的原则：

验收基线管结果对不对，执行边界管的是过程——即使结果正确，用错误的方法达成也不行。

这在我们的场景里有一个非常具体的含义：Agent 有可能"绕过搜索"去伪造一个解。因此我们设一道它无法绕过的边界：任何被宣布成功的图，都必须交给一个与搜索器完全独立实现的验证器复核（见 §4.3）。

三、已完成的基础（第一阶段，已验收）

新 Agent 不是从零开始——它需要一个硬环境才能工作。这部分已经建成：

已有设施	在新架构中的角色
位掩码增量代价引擎（违反度精确维护，约 10	Agent 的环境物理引擎（给得又准又快的反馈）

万次翻转/秒)	
独立验证器（显式邻接矩阵 + 子集枚举，与搜索器算法路径完全不同）	Agent 的真理判定器；也是防 reward hacking 的边界
评测场（训练/held-out 严格分离、固定墙钟预算、多种子、可断点续跑）	Agent 的评测场：它迭代出的算法要在这里被公平比较
25 个搜索算子（覆盖候选表/禁忌长度/扰动/退火四个维度）	Agent 的初始技能库
34 项回归测试（含与暴力枚举的全空间交叉验证）	约束层：任何新算法上台的门禁
逐轮 / 逐步 JSONL 日志	轨迹日志：Agent 状态栏与失败归因的数据来源

3.1 这一阶段得到的两个可写进报告的结论

结论一（判定性结果）：循环图族已被穷举排除。把搜索限制到循环图（自由参数从 $C(n,2)$ 降到 $n/2$, $n=43$ 时只有 21 个比特），把合法性判定化为位运算，并经过三处优化把判定速度从 455 提升到约 200 万配置/秒，从而可以穷举整个子族：

循环图族内存在合法 (5,5)-染色的最大 $n = 41$ ； $n \geq 42$ 全部判定性无解。


三重正确性保障：① 小 n 上与独立实现的代价函数逐配置全空间对比，零不一致；② 每个解过独立验证器；③ $n=46$ 无解的结论与已证明的 $R(5,5) \leq 46$ 一致。（推论： $n=43$ 无循环解，说明那条著名的 43 顶点构造必然不是循环图。）


结论二（负面，已定位机制）：把"过去找到的解"存起来热启动，比独立重启更差。四种解层记忆策略在两个预算区间内全部劣于冷启动。机制清晰：存下的近失解代价比一次冷启动能达到的还差，热启动把搜索锚定在平庸盆地——这与"约束全局耦合时好解不可分解"的判断一致。

正是这个否定结果促成了本次方向修正：增益来自算法本身，而"在固定算法集合里做选择"是一个退化的老虎机（其中一个臂全占优，数学上不可能赢）。要让 Agent 有价值，它必须能创造新算法，而不是只在旧算法里挑。这正是课程 §5.2.6 讲的"Agent 自举"。

四、新架构

4.1 总体结构





4.2 Agent 的运行规则（显式、可读、可审）

这是本项目的**核心主张**：规则不埋在代码的 **if** 里，而是一组**可打印、可审查、可修改**的规则。

规则	内容	为什么这样定
门禁规则	新算法必须先通过全部 34 项回归测试，否则不得进入评测	课程 §5.1.4"约束优先于指导": 用代码强制，而不是提示词请求
验证规则	任何代价为 0 的结果，必须经独立验证器复核才算成功	§5.1.4"执行边界": 防止 Agent 绕过搜索伪造解
预算规则	每轮迭代的评测时间固定；总预算按目标队列分配	保证不同算法之间可比，防止"多跑几次就算改进"
停滞规则	连续 N 轮无改进即判定该方向停滞，转入下一策略或下一目标	对应 §5.1.5 控制流层故障： 死循环与死亡螺旋
回退规则	任何被否决的改动都可一键回退到上一个已验证版本	§5.1.4"回退要可靠": 每个错误都可逆
记录规则	每轮必须记录：决定 / 理由 / 观察 / 结果	决策日志即作业要求的"体现智能体运行与迭代结果"
重试规则	先分类再计数：可重试错误（超时/限流）才重试，不可重试错误（参数非法）不得原样重试	§5.1.5"先分类，再计数"

4.3 自主迭代循环

- ① 分析 读轨迹日志：上轮结果如何？卡在哪？失败模式是什么？
 - ② 提出 确定性层先试预设策略；若无效，交给 LLM 归因并提出新算法思路
 - ③ 设计 写出简短设计说明（改哪个模块、为什么、预期影响）——课程 §5.1.3
 - ④ 实现 写代码（新算子 / 新技能 / 新参数策略）
 - ⑤ 门禁 跑 34 项回归测试 —— 不过就地丢弃，不进入评测
 - ⑥ 评测 在固定预算的评测场上对比（多种子、held-out）
 - ⑦ 决策 优于基线则保留并登记为技能；否则回退并记录原因
 - ⑧ 记录 写入决策日志与轨迹日志
- └───────────────────> 回到 ①

4.4 技能库（课程 §2.5 三层渐进式披露）

```
skills/  
  <skill-name>/  
    SKILL.md      # 第一层元数据: name + description（写成"何时用我/何时别用我"）  
                  # 第二层正文: 角色与读者 / 核心原则(3-5条+正反例)  
                  #                               / 禁止清单 / 参考资料  
    impl.py       # 可执行实现（技能可以捆绑代码）  
    reference.md  # 第三层: 深入细节，按需加载
```

关键点: **description** 是路由条件，不是功能罗列——"何时用我"比"我能做什么"重要得多。 目录常驻上下文（开销小），完整正文按需加载（开销大），这是兼顾能力与上下文成本的关键。

4.5 Agent 的知识（记忆的正确形态）

第一阶段证否的是"解层记忆"。本架构里 Agent 的知识是算法层的：

- 有哪些算法变体（可执行代码，课程 §3.1.4）
- 每个变体在什么情形下实测表现如何（按规模 / 预算 / 问题形状分档）
- 哪些改动被否决过、原因是什么（负面知识同样重要）

五、阶段计划

阶段	做什么	预期目标（可证伪）	交付物
A. 骨架 + 确定性层	任务层、规则引擎、决策循环、决策日志、技能库结构。 不依赖 LLM	Agent 能在无人干预下连续跑 ≥ 1 小时，产出完整可读的决策日志；规则可被外部审查	可运行的 Agent 骨架 + 一份真实运行日志
B. 接入 LLM	接模型接口做失败归因与"提出新算法思路/写新算子代码"	LLM 提出的新算子中，至少有一个通过门禁并在评测场上优于初始技能库最优算子	LLM 规划器 + 新算子的评测报告
C. 长时程自主 + 目标	多目标任务、预算分	给定 3 个以上目标与	调度器 + 对照实验

队列	配、停滞转移、跨目标调度	总预算，Agent 自行分配，且分配结果 优于均匀分配基线	
D. 评测 Agent 本身	把"自主迭代"与"人工固定策略"做对照	自主迭代出的算法在 held-out 上优于任何单一固定算法（多种子、多种度量交叉验证）	Agent 能力评估报告
E. 应用产出	用 Agent 攻开放靶子	$R(5,5)$ 的 $n=44$ 或 45 上找到合法染色（找到 45 即 $R(5,5)=46$ ）；或 $R(4,6)$ 下界 3536	新结果，或带瓶颈定位的负报告
F. 报告与迁移	汇总为 PDF；把框架迁到第二个问题	在 ≥ 2 个新问题上跑通完整流程	最终报告 + 通用骨架

六、评价标准（我们如何证明"Agent 有价值"）

这是本项目最需要设计清楚的地方。三条判据，都必须可证伪：

- 4. **自主性**：给定任务与预算，Agent 能否**无人干预**地连续工作并产出可用结果？（判据：连续运行时长 + 决策日志的完整性与可读性）
- 5. **迭代有效性**：Agent 自主迭代出的算法，是否**优于它出发时拥有的最优算法**？（判据：在 held-out 上、固定预算、多种子对比，全部成功过独立验证器）
- 6. **决策质量**：Agent 的预算分配与切换时机是否合理？（判据：**自适应分配 vs 均匀分配**的对照实验）

第 3 条是特意设计的：第一阶段我们曾经用"25 个算子里挑一个"去检验智能体层，那是个退化的老虎机（一个臂全占优，数学上不可能赢）。这次的检验落在正确的层次上——目标选择与预算分配，这一层不存在"某个固定答案必然最优"。

七、时间安排（建议，可随课程节奏调整）

阶段	建议周期	里程碑
A	2 周	Agent 骨架可无人值守运行，日志完整
B	2~3 周	LLM 提出的新算子通过门禁且优于基线
C	2 周	目标队列 + 预算分配，且优于均匀分配

D	1~2 周	Agent 能力评估报告
E	3~4 周	开放靶子的结果或负报告
F	2 周	最终报告 + 迁移案例

八、风险与应对

风险	应对
LLM 提出的算法质量差	两层架构保证：确定性层不依赖 LLM，系统始终可运行；LLM 只是增益项
Agent 用错误方法"刷分"（reward hacking）	独立验证器 + 过程约束 ：成功必须经独立复核；新算法必须先过回归门禁
没有可用的模型 API	阶段 A 完全不依赖 LLM，可独立交付；LLM 是插槽而非前提
开放靶子攻不下来	已有预案：如实产出负报告 + 瓶颈定位（本项目已有三次这样的先例）
自主迭代的收益不明显	阶段 D 的对照实验本身就是结论；若无效则说明"自主迭代"在此场景不成立，同样是有有效结论

九、诚实边界

- 不承诺解决 $R(5,5)$ 。上界 46 由 LP + 大规模分类讨论证出；构造侧 $n=44/45$ 是逻辑上"找到即定值"的真靶子，但难度是天文级的。它是北极星，不是排期假设。
- 第一阶段的核心假设（记忆增强）已被我们自己的数据否定，并且我们给出了机制解释。本次方向修正正是基于这个否定结果，不是回避它。
- "自主迭代算法"目前还是设计，不是已验证的能力。阶段 B/C/D 才检验它；如果检验失败，那也是有价值的结论。

十、已交付物与仓库

交付物	位置
项目主页（含完整说明与复现步骤）	GitHub: Bitwild4ever/marsa-ramsey-agent
本规划书	项目规划书.md / .pdf
第一阶段实验报告（含图表与诚实声明）	实验报告.pdf / .md
阶段 1 记录（算子组合与消融）	阶段 1_算子组合实验.md
阶段 2 记录（循环图完整刻画）	阶段 2_对称族实验.md

选题说明	选题说明.pdf / .md
代码与测试	marisa/（8 个模块）、tests/（34 项）、scripts/（14 个实验脚本）
原始实验数据	runs/（逐轮 / 逐步 JSONL 日志）

规划书 v2 · 取代 v1 · 第一阶段收尾、第二阶段起点